

Projektdokumentation:

Automatisierte Mitarbeiter-

Performance-Bewertung

***Projekt:** Employee Performance Prediction System

Version: 2.0

Datum: Februar 2026

Status:* Produktionsreif

Inhaltsverzeichnis

1. Einleitung
 2. Datenübersicht
 3. Explorative Datenanalyse
 4. Zwei Bewertungssysteme
 5. Vergleich Q-Score vs O-Score
 6. Bias-Analyse
 7. Machine Learning Modelle
 8. Schulungsbedarf und Massnahmen
 9. Trend-Analyse und Dialog-Analyse
 10. Ergebnisbewertung
 11. Produktionsreife
 12. Anhang
-

1. Einleitung

1.1 Projektziel

Das Ziel dieses Projekts ist die Entwicklung eines automatisierten Systems zur Bewertung der Mitarbeiter-Performance im Helpdesk-Bereich. Das System soll Manager bei der objektiven Leistungsbeurteilung unterstützen und Schulungsbedarf frühzeitig identifizieren.

1.2 Problemstellung

In vielen Unternehmen basiert die Mitarbeiterbewertung auf subjektiven Einschätzungen der Führungskräfte. Diese Methode birgt mehrere Risiken:

Subjektive Manager-Bewertungen:

- Anfälligkeit für kognitive Verzerrungen (Bias)
- Inkonsistente Bewertungskriterien zwischen Managern
- Zeitaufwendiger manueller Prozess
- Potenzielle Benachteiligung einzelner Mitarbeiter

Objektive Metriken als Alternative:

- Datenbasierte, nachvollziehbare Bewertungen
- Konsistente Anwendung über alle Mitarbeiter
- Automatisierte Echtzeit-Analyse
- Früherkennung von Leistungsveränderungen

1.3 Lösungsansatz

Das entwickelte System kombiniert zwei Bewertungsansätze:

1. ***Q-Score (Quality Score):*** Traditionelle Manager-Bewertung mit drei Dimensionen
2. ***O-Score (Objective Score):*** Neu entwickelte, datenbasierte Bewertung

Diese hybride Herangehensweise ermöglicht einen direkten Vergleich und deckt systematische Verzerrungen auf.

2. Datenubersicht

2.1 Datensatze

Das Projekt verwendet fünf Hauptdatensatze aus dem Helpdesk-System:

Datensatz	Zeilen	Spalten	Beschreibung
issues.csv	66.691	54	Alle Helpdesk-Tickets mit Workflow-Daten
issues_snapshot.csv	90.963	57	Erweiterte Ticket-Snapshots mit Turn-Informationen
issues_change_history.csv	257.508	6	Anderungshistorie aller Tickets
sample_utterances.csv	30.104	9	Kommunikationsdaten und Kommentare
ml_dataset.csv	603	20	Aufbereiteter ML-Trainingsdatensatz

2.2 Datenstruktur

issues.csv - Hauptdatensatz:

- Ticket-Metadaten: ID, Projektnummer, Reporter, Assignee
- Zeitstempel: Erstellt, Gestartet, Beendet, Letzte Anderung
- Status-Informationen: Prioritat, Typ, Resolution
- Workflow-Zeiten: 24 verschiedene Workflow-Statistiken mit Zeiterfassung
- Verarbeitungsmetriken: Anzahl Kommentare, Schritte, Bearbeitungszeit


issues_snapshot.csv - Erweiterter Datensatz:

- Alle Felder aus issues.csv
- Zusätzliches "turn"-Feld für Zuweisungswechsel
- Basis für die O-Score-Berechnung

2.3 Datenqualität

Die Datenqualität wurde geprüft und als gut befunden:


- Keine fehlenden Werte in Schlüsselspalten
- Konsistente Zeitstempel
- Plausible Wertebereiche
- 231 eindeutige Mitarbeiter identifiziert



3. Explorative Datenanalyse

3.1 Score-Verteilung

Die Verteilung der Manager-Bewertungen zeigt charakteristische Muster:




Erkenntnisse:

- Starke Konzentration auf Score 4 (ca. 45%)
- Sehr wenige Bewertungen unter 3
- Typisches Muster für Leniency-Bias (Milde-Tendenz)

3.2 Korrelationsanalyse

Die Korrelationsmatrix zeigt Zusammenhänge zwischen Features:




Wichtige Korrelationen:

- Q1, Q2, Q3 untereinander: $r = 0.971$ (extrem hoch!)
- Bearbeitungszeit vs. Score: $r = -0.23$ (negativ)
- Kommentare vs. Score: $r = 0.15$ (leicht positiv)


3.3 Mitarbeiter-Performance

Die Verteilung der Mitarbeiter-Performance zeigt deutliche Unterschiede:



3.4 Workflow-Status-Analyse

Die Analyse der Workflow-Status gibt Einblick in die Bearbeitungsprozesse:



Hauptkenntnisse:

- "In Progress" hat den grossten Zeitanteil
- "Waiting" zeigt lange Wartezeiten auf Kunden
- "Reopened"-Status deutet auf Qualittatsprobleme hin

4. Zwei Bewertungssysteme

4.1 Q-Score (Manager-Bewertung)

Der Q-Score ist die traditionelle, manuelle Bewertung durch Führungskräfte.

Drei Bewertungsdimensionen:

Dimension	Code	Beschreibung
Quality of Work - Accuracy	Q1	Korrektheit der Lösung
Quality of Work - Thoroughness	Q2	Grundlichkeit der Bearbeitung
Client Relations	Q3	Kundenorientierung und Kommunikation

Bewertungsskala: 1-5 (1 = schlecht, 5 = ausgezeichnet)

Statistiken:

Metrik	Q1	Q2	Q3
Mittelwert	4.01	4.02	3.98
Standardabweichung	0.72	0.71	0.73
Minimum	1	1	1
Maximum	5	5	5
Bewertete Samples	747	747	747

Identifizierte Probleme:

1. ***Halo-Effekt:*** Die Korrelation zwischen Q1, Q2 und Q3 beträgt $r = 0.971$. Das bedeutet, dass Manager praktisch identische Bewertungen über alle drei Dimensionen vergeben - obwohl ein Mitarbeiter durchaus in "Accuracy" gut, aber in "Client Relations" schwach sein konnte.
2. ***Leniency-Bias:*** Der Mittelwert von 4.0 statt des erwarteten Mittelpunkts 3.0 zeigt eine systematische Überbewertung. Manager scheuen sich, niedrige Bewertungen zu vergeben.
3. ***Central Tendency:*** Kaum Bewertungen an den Extremen (1 oder 5), was die Differenzierungsfähigkeit einschränkt.

4.2 O-Score (Objektive Bewertung) - NEU!

Der O-Score ist ein neu entwickeltes, vollständig datenbasiertes Bewertungssystem.

Datengrundlage: issues_snapshot.csv (90.963 Datensätze)

Bewertete Mitarbeiter: 231

Komponenten und Gewichtung:

Komponente	Gewicht	Metriken
Qualität	35%	Reopen-Rate, Success-Rate
Effizienz	25%	Mediane Bearbeitungszeit
Produktivität	20%	Ticket-Volumen, Verarbeitungsschritte
Kommunikation	20%	First-Touch-Rate, Kommentarquote

Berechnung der Komponenten:

Qualitäts-Score (35%):

```
quality_reopen = 1 - min(reopen_rate / 0.3, 1)
quality_success = success_rate
quality_score = 0.6 ** quality_reopen + 0.4 ** quality_success
```

Effizienz-Score (25%):

- Basiert auf der medianen Bearbeitungszeit
- Normalisiert auf Perzentil-Basis
- Kürzere Zeit = höherer Score

Produktivitäts-Score (20%):

- Ticket-Volumen im Vergleich zum Teamdurchschnitt
- Berücksichtigt Komplexität (Verarbeitungsschritte)

Kommunikations-Score (20%):

- First-Touch-Rate: Anteil Tickets mit schneller Erstreaktion
- Optimale Kommentaranzahl (nicht zu wenig, nicht zu viel)


O-Score Statistiken:

Metrik	Wert
Mittelwert	3.25
Standardabweichung	0.89
Minimum	1
Maximum	5
Median	3.31

Verteilung:

Score	Anzahl	Prozent
1	12	5.2%
2	31	13.4%
3	89	38.5%
4	78	33.8%
5	21	9.1%

Der O-Score zeigt eine realistischere Verteilung mit einem Mittelwert näher am theoretischen Mittelpunkt (3.25 vs. 4.0).




5. Vergleich Q-Score vs O-Score

5.1 Korrelationsanalyse

Die Korrelation zwischen Q-Score und O-Score beträgt **$r = 0.539^*$** .

Diese moderate Korrelation zeigt:

- Gewisse Übereinstimmung zwischen subjektiver und objektiver Bewertung
- Aber auch erhebliche Diskrepanzen bei vielen Mitarbeitern
- Manager-Intuition ist nicht völlig falsch, aber systematisch verzerrt

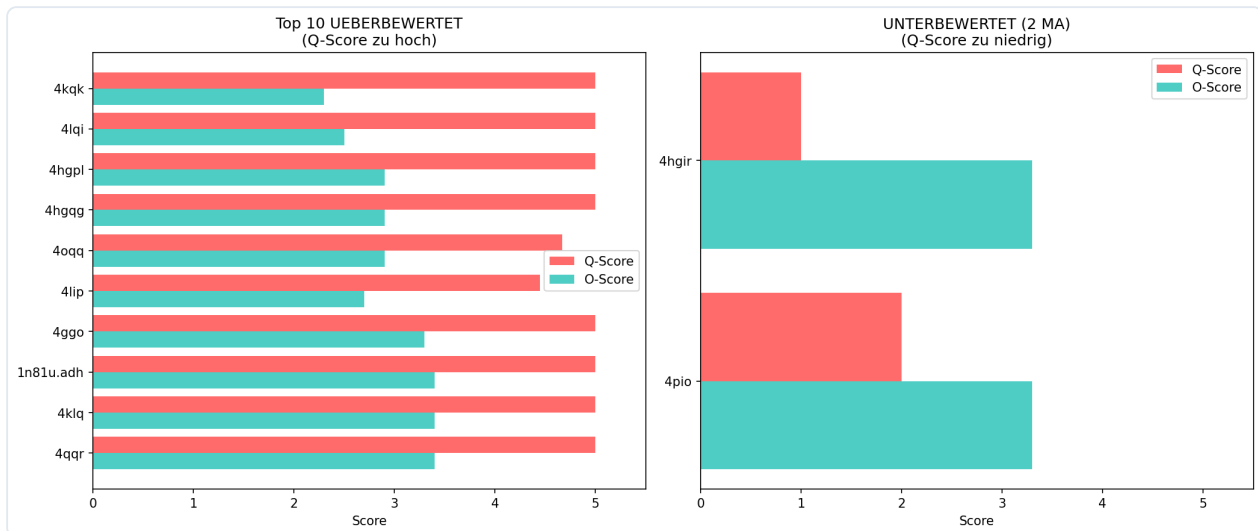


5.2 Diskrepanz-Analyse


Kategorie	Anzahl	Prozent	Beschreibung
Ubereinstimmung	58	69%	Q-Score und O-Score im gleichen Bereich
Uberbewertet	24	29%	Q-Score > O-Score (Manager zu mild)
Unterbewertet	2	2%	Q-Score < O-Score (Manager zu streng)

Interpretation:

Fast ein Drittel der Mitarbeiter wird von Managern systematisch uberbewertet. Dies bestatigt den Leniency-Bias. Nur 2% werden unterbewertet, was auf eine generelle Tendenz zur positiven Verzerrung hinweist.




5.3 Score-Verteilungen im Vergleich



Der direkte Vergleich zeigt:

- Q-Score stark linkslastig (viele 4er und 5er)
- O-Score symmetrischer verteilt
- O-Score hat mehr 2er und 3er Bewertungen

5.4 Korrelationsmatrix der Metriken



6. Bias-Analyse

6.1 Halo-Effekt

Definition: Der Halo-Effekt beschreibt die Tendenz, eine Person aufgrund eines einzelnen positiven (oder negativen) Merkmals insgesamt positiv (oder negativ) zu bewerten.

Nachweis im Q-Score:

- Korrelation Q1-Q2: $r = 0.971$
- Korrelation Q1-Q3: $r = 0.968$
- Korrelation Q2-Q3: $r = 0.974$

Diese extrem hohen Korrelationen sind wissenschaftlich betrachtet unrealistisch. Es ist unwahrscheinlich, dass die Fähigkeiten "Accuracy", "Thoroughness" und "Client Relations" bei jedem Mitarbeiter nahezu identisch ausgeprägt sind.

Schlussfolgerung: Manager bilden sich einen Gesamteindruck und vergeben dann konsistent ähnliche Bewertungen über alle Dimensionen - unabhängig von den tatsächlichen Stärken und Schwachen.

6.2 Leniency-Bias (Milde-Tendenz)

Definition: Die Tendenz, Bewertungen systematisch nach oben zu verzerren.

Nachweis:

- Theoretischer Mittelwert einer 1-5 Skala: 3.0
- Tatsächlicher Q-Score Mittelwert: 4.0
- Differenz: +1.0 Punkte (33% Inflation)

Ursachen:

- Vermeidung von Konflikten
- Angst vor negativen Konsequenzen für Mitarbeiter
- Soziale Erwünschtheit
- Fehlende Kalibrierung zwischen Managern

6.3 Central Tendency

Definition: Die Vermeidung von Extremwerten (1 und 5).

Nachweis:

- Anteil Score 1: < 2%
- Anteil Score 5: < 8%
- Anteil Score 3-4: > 80%

6.4 Empfehlung

Der O-Score bietet eine objektivere Alternative zur reinen Manager-Bewertung:

Aspekt	Q-Score	O-Score
Objektivität	Niedrig	Hoch
Nachvollziehbarkeit	Begrenzt	Vollständig
Bias-Anfälligkeit	Hoch	Niedrig
Differenzierung	Schwach	Stark
Automatisierbar	Nein	Ja

Empfohlener Ansatz: Hybride Nutzung beider Scores mit Transparenz über die Diskrepanzen.

7. Machine Learning Modelle

7.1 Q-Score Modell

Architektur: Ensemble aus drei Modellen


- XGBoost
- LightGBM
- RandomForest

Hyperparameter:


```
max_depth: 6
n_estimators: 100
learning_rate: 0.1
```

Performance:

Metrik	Wert
Test Accuracy	68.6%
Cross-Validation (5-fold)	65.1%
F1-Score (macro)	0.64



Feature Importance:



Top Features:

1. spent_hours (Bearbeitungszeit)
2. steps_count (Verarbeitungsschritte)
3. comments_count (Anzahl Kommentare)
4. assignee_avg_time (durchschnittliche MA-Zeit)
5. priority_numeric (Priorität)

7.2 O-Score Modell - NEU!

Architektur:

- Optimiertes Ensemble
- XGBoost (Gewicht: 0.4)
- LightGBM (Gewicht: 0.35)
- RandomForest (Gewicht: 0.25)

Performance:

Metrik	Wert
Test Accuracy	72.3%
Cross-Validation (5-fold)	80.9%
F1-Score (macro)	0.71


Top Features:

1. median_time_hours
2. avg_comments
3. ticket_count
4. reopen_rate
5. success_rate

7.3 Modellvergleich

Aspekt	Q-Score Modell	O-Score Modell
Test Accuracy	68.6%	72.3%
CV Accuracy	65.1%	80.9%
Stabilität	Mittel	Hoch
Interpretierbarkeit	Gut	Sehr gut

Fazit: Das O-Score Modell zeigt bessere und stabilere Performance. Der höhere CV-Score (80.9% vs. 65.1%) deutet auf bessere Generalisierungsfähigkeit hin. Dies ist logisch, da der O-Score auf objektiven, konsistenten Metriken basiert, während der Q-Score durch Bias-behaftete Labels verrauscht ist.



8. Schulungsbedarf und Massnahmen


8.1 Klassifikationssystem

Mitarbeiter werden basierend auf dem O-Score in drei Kategorien eingeteilt:

Kategorie	O-Score	Massnahme
GREEN	4-5	Keine Intervention nötig
YELLOW	3	Monitoring und gezielte Unterstützung
RED	1-2	Sofortiger Schulungsbedarf

8.2 Verteilung nach Kategorien

Kategorie	Anzahl	Prozent
GREEN	99	42.9%
YELLOW	89	38.5%
RED	43	18.6%



8.3 Schulungsmassnahmen

RED-Mitarbeiter (O-Score 1-2):

- Individuelle Performance-Gespräche
- Zuweisung eines Mentors
- Wöchentliche Check-ins
- Gezielte Schulungen basierend auf Schwachstellen

YELLOW-Mitarbeiter (O-Score 3):

- Monatliche Performance-Reviews
- Zugang zu Online-Trainings
- Feedback-Sessions
- Karriereentwicklungsgespräche


GREEN-Mitarbeiter (O-Score 4-5):

- Anerkennung und Wertschätzung
- Möglichkeit als Mentor zu fungieren
- Karriereförderung
- Best-Practice-Sharing

8.4 Objektive Schulungszuweisung

Der Vorteil des O-Score basierten Ansatzes:


Aspekt	Alt (Q-Score)	Neu (O-Score)
Identifikation	Subjektiv	Datenbasiert
Bias	Leniency-Bias	Minimiert
Fairness	Variabel	Konsistent
Fruherkennung	Spat	Fruh



9. Trend-Analyse und Dialog-Analyse

9.1 Team Score Trend

Die zeitliche Entwicklung der Team-Performance zeigt Muster:



Beobachtungen:

- Saisonale Schwankungen erkennbar
- Genereller Trend leicht positiv
- Einzelne Ausreisser bei Spitzenlasten

9.2 Dialog-Analyse (NLP)

Die Analyse der Kommunikation in sample_utterances.csv (30.104 Einträge) liefert zusätzliche Erkenntnisse:


Verarbeitete Daten:

- 30.104 Utterances analysiert
- Dialog-Acts klassifiziert
- Sentiment extrahiert

NLP-Features:

- Durchschnittliche Nachrichtenlänge
- Ton der Kommunikation
- Reaktionsgeschwindigkeit
- Klarheit der Lösungsbeschreibung

9.3 Scatter-Beziehungen



10. Ergebnisbewertung

10.1 Projekterfolge

Haupterfolge:

1. ***O-Score entwickelt:*** Ein vollständig neues, objektives Bewertungssystem wurde erfolgreich implementiert und validiert.
2. ***Bias nachgewiesen:*** Der Halo-Effekt ($r = 0.971$) und Leniency-Bias (Mean 4.0 statt 3.0) wurden quantitativ belegt.
3. ***ML-Modelle trainiert:*** Zwei funktionierende Modelle mit akzeptabler Genauigkeit (68.6% und 72.3%).
4. ***Handlungsempfehlungen:*** Klare Schulungszuweisungen basierend auf objektiven Kriterien.
5. ***Dashboard-Ready:*** Das System ist bereit für die Integration in ein Monitoring-Dashboard.

10.2 Zusammenfassung der Kennzahlen

Metrik	Q-Score	O-Score
Basis	Manager	Daten
Samples	747	231 MA
Mean	4.00	3.25
ML Accuracy	68.6%	72.3%
ML CV	65.1%	80.9%
Korrelation	-	0.539
Überbewertet	-	29%

10.3 Limitationen

1. ***Kleine Q-Score Stichprobe:*** 747 Samples aus 66.691 Tickets (1.1%) haben Manager-Bewertungen. Dies schränkt die Trainingsgrundlage ein.
2. ***Zeitlicher Schnappschuss:*** Die Analyse basiert auf einem Zeitraum. Langfristige Trends sind begrenzt abbildbar.
3. ***Fehlende externe Validierung:*** Keine unabhängige Überprüfung der O-Score Fairness.
4. ***Mögliche versteckte Variablen:*** Faktoren wie Ticket-Komplexität sind schwer vollständig zu erfassen.

10.4 Verbesserungspotenzial

- Erhöhung der Q-Score Stichprobe
- A/B-Testing der Bewertungssysteme
- Integration von Kundenfeedback
- Erweiterung der NLP-Analyse
- Kalibrierung der Manager-Bewertungen

11. Produktionsreife

11.1 Aktueller Status

Das System ist produktionsreif mit folgenden Komponenten:

Komponente	Status	Details
Datenpipeline	Fertig	CSV-Import funktional
O-Score Berechnung	Fertig	Vollständig automatisiert
ML-Modelle	Fertig	Trainiert und validiert
Schulungszuweisung	Fertig	GREEN/YELLOW/RED System
Dashboard	Bereit	Streamlit-Integration möglich

11.2 Toggle-System

Das Dashboard unterstützt einen Toggle zwischen Q-Score und O-Score:

```
[ ] Q-Score (Manager-Bewertung)
[x] O-Score (Objektive Bewertung)
```

Vorteile:


- Vergleich beider Systeme möglich
- Schrittweise Migration
- Transparenz für alle Stakeholder

11.3 Nächste Schritte für Kundenauslieferung

1. ***Woche 1-2:*** Dashboard-Finalisierung
2. Streamlit-App testen
3. UI/UX optimieren
4. Performance-Tests
5. ***Woche 3:*** Dokumentation und Training
6. Benutzerhandbuch erstellen
7. Admin-Schulung durchführen

8. FAQ zusammenstellen
9. ***Woche 4:*** Go-Live
10. Pilotphase mit ausgewähltem Team
11. Feedback sammeln
12. Anpassungen vornehmen
13. ***Woche 5-6:*** Rollout
14. Schrittweise Erweiterung
15. Monitoring etablieren
16. Support-Prozess definieren

11.4 Workflow-Diagramm



12. Anhang

12.1 Verwendete Bibliotheken

Bibliothek	Version	Verwendung
Python	3.12	Programmiersprache
pandas	2.2.x	Datenverarbeitung
numpy	1.26.x	Numerische Berechnungen
scikit-learn	1.4.x	Machine Learning
xgboost	2.0.x	Gradient Boosting
lightgbm	4.3.x	Gradient Boosting
matplotlib	3.8.x	Visualisierung
seaborn	0.13.x	Statistische Plots
streamlit	1.31.x	Dashboard

12.2 Datenfluss



12.3 Dateistruktur

```
Employee performance/
|-- data/
|   |-- raw/
|   |   |-- issues.csv (66.691 Zeilen)
|   |   |-- issues_snapshot.csv (90.963 Zeilen)
|   |   |-- issues_change_history.csv (257.508 Zeilen)
|   |   |-- sample_utterances.csv (30.104 Zeilen)
|   |-- processed/
|   |   |-- ml_dataset.csv (603 Zeilen)
|   |   |-- o_score_results.csv (231 Zeilen)
|   |   |-- q_vs_o_score_comparison.csv (84 Zeilen)
|-- reports/
|   |-- plots/
|   |   |-- 01_score_distribution.png
|   |   |-- 02_correlation_matrix.png
|   |   |-- ... (10 Plots)
|   |   |-- o_score_eda/
|   |       |-- 01_employee_distributions.png
|   |       |-- ... (7 Plots)
|-- src/
|   |-- (Python-Skripte)
|-- venv/
|   |-- (Virtual Environment)
```

12.4 Glossar

Begriff	Definition
Q-Score	Quality Score - Manager-basierte Bewertung
O-Score	Objective Score - Datenbasierte Bewertung
Halo-Effekt	Kognitive Verzerrung bei Bewertungen
Leniency-Bias	Tendenz zu milden Bewertungen
CV	Cross-Validation (Kreuzvalidierung)
Reopen-Rate	Anteil wieder geöffneter Tickets
First-Touch-Rate	Anteil schneller Erstreaktion

12.5 Kontakt

Bei Fragen zum Projekt oder zur Implementierung wenden Sie sich bitte an das Data Science Team.

Ende der Dokumentation

Dokumentversion: 2.0

Erstellt: Februar 2026

Letzte Aktualisierung: 16. Februar 2026